社團讀書交流活動

第9週文件處理與資料前處理｜虛構教學資料

一、活動資訊

活動日期：2026年11月11日（星期三）。

活動時間：下午2時至4時。

活動地點：圖書館討論室。

報名截止：2026年11月6日（星期五）。

每組最多4人，共開放8組，總名額32人。

二、參加方式

參加者先閱讀一篇短文，再分組討論資料來源與內容。

報名方式由社團另行公告；本文件未提供報名網址。

本文件未提供活動費用，不能推論為免費。

三、文件處理練習

逐頁抽取文字，核對日期、時間、地點與人數。

清理多餘空白時，保留段落、標點與數字。

本檔案含可抽取的文字層，不是掃描影像。

討論流程與查核紀錄

第9週文件處理與資料前處理 | 虛構教學資料

一、活動流程

下午2時至2時20分：閱讀短文並標記資訊來源。

下午2時20分至3時20分：分組討論與內容核對。

下午3時20分至4時：分享發現並整理待確認問題。

二、切塊與來源核對

固定chunk_size為120，比較overlap為0與20的結果。

start與end指向清理後文字的位置，end不包含在切片內。

每個chunk的text應等於cleaned_text[start:end]。

下載JSON後重新讀回，核對片段、參數與來源位置。

三、人工查核

確認每組4人、8組，合計32人，沒有被清理程式刪除。

比較PDF原檔與抽取文字，確認頁面順序及段落仍可辨識。

活動費用與報名網址屬於待確認資訊，不得自行補造。

四、使用範圍

本文件為課堂測試自編內容，不含真實個資或機密。

Notebook可直接讀取；App請透過上傳元件選取此檔。